

Choix d'un traitement médical par algorithmes de recommandation

DAGON Lucas

CLAUDE Loïc

2025 - 2026

Rappel du sujet

Dans un essai clinique, il est crucial d'identifier rapidement le traitement le plus efficace, tout en équilibrant deux objectifs :

- l'exploration : tester différents traitements ;
- l'exploitation : administrer le traitement actuellement considéré comme le meilleur.

Ce projet modélise cette problématique à l'aide de stratégies de décision adaptatives.

On dispose de cinq traitements A, B, C, D et E , ainsi que de 1000 patients. Chaque patient reçoit l'un des traitements, puis le résultat est observé (succès ou échec).

Les probabilités théoriques d'efficacité sont inconnues.

L'objectif est de déterminer une stratégie maximisant le nombre total de succès observés.

Il est important de raisonner “en moyenne”, car une même stratégie peut produire des résultats différents selon les réalisations aléatoires.

Les algorithmes réalisant un compromis entre exploration et exploitation sont généralement qualifiés d'algorithmes d'apprentissage par renforcement.

1 La stratégie aléatoire

Cette première stratégie est une stratégie naïve : à chaque instant n , on choisit l'un des traitements de manière uniforme au hasard.

On considère :

$$N = 1000$$

patients et cinq traitements de probabilités d'efficacité inconnues :

$$p_1, p_2, p_3, p_4, p_5 \in [0, 1].$$

Pour chaque patient n , on note :

$$X_n \in \{0, 1\}$$

avec :

$$X_n = \begin{cases} 1 & \text{si le traitement est efficace,} \\ 0 & \text{sinon.} \end{cases}$$

Le rôle de l'aléatoire

L'aléatoire intervient à deux niveaux :

— **L'aléatoire décisionnel :**

Le traitement administré au patient n est noté T_n :

$$T_n \sim \mathcal{U}\{1, 2, 3, 4, 5\}$$

donc :

$$\mathbb{P}(T_n = i) = \frac{1}{5}.$$

— **L'aléatoire naturel :**

L'efficacité du traitement est modélisée par une loi de Bernoulli :

$$X_n \mid (T_n = i) \sim \mathcal{B}(p_i).$$

Espérance

On obtient :

$$\mathbb{E}[X_n] = \frac{p_1 + p_2 + p_3 + p_4 + p_5}{5}.$$

Donc :

$$\mathbb{E}[X] = N \times \frac{p_1 + p_2 + p_3 + p_4 + p_5}{5}.$$

Variance

Pour un traitement fixé :

$$\text{Var}(X_n \mid T_n = i) = p_i(1 - p_i).$$

La variance totale peut être décomposée grâce à la formule :

$$\text{Var}(X_n) = \mathbb{E}[\text{Var}(X_n \mid T_n)] + \text{Var}(\mathbb{E}[X_n \mid T_n]).$$

On obtient :

$$\mathbb{E}[\text{Var}(X_n \mid T_n)] = \frac{1}{5} \sum_{i=1}^5 p_i(1 - p_i)$$

et :

$$\text{Var}(\mathbb{E}[X_n \mid T_n]) = \frac{1}{5} \sum_{i=1}^5 (p_i - \bar{p})^2$$

où :

$$\bar{p} = \frac{1}{5} \sum_{i=1}^5 p_i.$$

Interprétation

L'espérance est symétrique : tous les traitements contribuent de manière identique, qu'ils soient efficaces ou non.

La variance comporte :

- une part liée au caractère aléatoire des traitements ;
- une part liée à la différence d'efficacité entre les traitements.

Cette stratégie ne permet donc ni d'identifier ni d'exploiter les meilleurs traitements.

2 La stratégie cyclique

Cette deuxième stratégie reste naïve, mais les traitements sont administrés de manière cyclique.

Les traitements sont attribués successivement :

$$A \rightarrow B \rightarrow C \rightarrow D \rightarrow E \rightarrow A \dots$$

puis le cycle recommence.

Le choix du traitement devient donc déterministe.

L'unique source d'aléatoire provient désormais de l'efficacité des traitements.

Avec :

$$N = 1000 = 5 \times 200,$$

chaque traitement reçoit exactement :

$$k = \frac{N}{5} = 200$$

patients.

On obtient alors :

$$X_i \sim \mathcal{B}(200, p_i).$$

Espérance

Pour chaque traitement :

$$\mathbb{E}[X_i] = 200p_i.$$

Donc :

$$\mathbb{E}[X] = \frac{N(p_1 + p_2 + p_3 + p_4 + p_5)}{5}.$$

L'espérance est identique à celle de la stratégie aléatoire.

Variance

Puisque :

$$X_i \sim \mathcal{B}(200, p_i),$$

on a :

$$\text{Var}(X_i) = 200p_i(1 - p_i).$$

On remarque alors :

$$\text{Var}(X_{\text{cyclique}}) \leq \text{Var}(X_{\text{aléatoire}}).$$

Interprétation

Cette stratégie est plus structurée que la stratégie aléatoire : chaque traitement est testé exactement le même nombre de fois, ce qui rend les résultats plus stables.

- L'espérance reste identique à celle de la stratégie aléatoire ;
- La variance est plus faible ;
- Cependant, la stratégie reste non adaptative.

Elle ne permet donc toujours pas d'exploiter les meilleurs traitements.

3 La stratégie du meilleur traitement observé

Pour cette méthode, nous utiliserons en partie la loi de Student, qui est une loi de probabilité permettant d'avoir une idée du nombre recherché à partir d'un échantillon et pour construire un intervalle de confiance ou est notre valeur.

Cette stratégie se déroule en deux phases.

Phase 1 : exploration

Pour les patients 1 à $5m$, on administre exactement m fois chaque traitement.

À l'issue de cette phase, on calcule pour chaque traitement sa moyenne empirique de succès.

Phase 2 : exploitation adaptative

Pour les patients suivants :

$$5m + 1 \rightarrow N,$$

on administre le traitement ayant la meilleure moyenne empirique observée.

Les estimations sont mises à jour après chaque patient.

Pourquoi le calcul exact est difficile ?

Le traitement choisi dépend de l'ensemble des résultats observés précédemment.

Ainsi, le choix du traitement devient lui-même une variable aléatoire dépendant de l'historique.

Le calcul exact de :

$$\mathbb{E}[X] = 5m \times p$$

devient donc difficile.

Approximation

Afin de simplifier l'étude, on suppose que la phase d'exploitation est figée :

après la phase d'exploration, on choisit définitivement le traitement ayant obtenu la meilleure moyenne.

Le coût de l'exploration doit rester faible devant le nombre total de patients :

$$5m \ll N.$$

Comme :

$$N = 1000,$$

on obtient :

$$m \ll \frac{N}{5} = 200.$$

Choix du paramètre m

Le paramètre m doit équilibrer deux effets :

- si m est trop petit, les estimations sont peu fiables ;
- si m est trop grand, trop de patients sont utilisés pour l'exploration.

Dans notre étude, nous avons choisi :

$$m = 30,$$

ce qui constitue un bon compromis entre exploration et exploitation.

Interprétation

Cette stratégie est plus efficace que les précédentes, car elle introduit une phase d'apprentissage.

- Elle permet d'identifier empiriquement les traitements les plus prometteurs ;
- elle améliore les performances globales en concentrant progressivement les patients sur les meilleurs traitements.

3.1 Distribution Beta

Thompson Sampling utilise une **distribution Beta** pour modéliser la probabilité de succès de chaque traitement. La distribution Beta est définie par deux paramètres : α (nombre de succès observés) et β (nombre d'échecs observés).

La fonction de densité de probabilité de la distribution Beta est :

$$f(p; \alpha, \beta) = \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} p^{\alpha-1} (1-p)^{\beta-1} \quad (1)$$

où $p \in [0, 1]$ représente la probabilité de succès, et Γ est la fonction Gamma.

3.2 Processus Bayésien

Le processus de mise à jour suit le théorème de Bayes :

$$P(\theta|\text{données}) \propto P(\text{données}|\theta) \cdot P(\theta) \quad (2)$$

La propriété conjuguée de la distribution Beta avec la distribution de Bernoulli garantit que la distribution postérieure reste une distribution Beta.

4 Algorithme Thompson Sampling

4.1 Principe Général

À chaque étape t , l'algorithme suit ce processus en trois phases :

4.1.1 Phase 1 : Échantillonnage

Pour chaque traitement $k \in \{1, 2, \dots, K\}$, on échantillonne une valeur $\theta_k^{(t)}$ de la distribution Beta courante :

$$\theta_k^{(t)} \sim \text{Beta}(\alpha_k^{(t)}, \beta_k^{(t)}) \quad (3)$$

où $\alpha_k^{(t)}$ et $\beta_k^{(t)}$ sont les paramètres accumulés jusqu'à l'étape t .

4.1.2 Phase 2 : Sélection

On sélectionne le traitement ayant la plus haute valeur échantillonnée :

$$a_t = \arg \max_{k \in \{1, \dots, K\}} \theta_k^{(t)} \quad (4)$$

Cette stratégie équilibre naturellement l'exploration (traitements moins bien connus) et l'exploitation (traitements prometteurs).

4.1.3 Phase 3 : Mise à Jour

Après observation du résultat $r_t \in \{0, 1\}$ du traitement a_t , les paramètres sont mis à jour selon :

$$\alpha_{a_t}^{(t+1)} = \alpha_{a_t}^{(t)} + r_t \quad (5)$$

$$\beta_{a_t}^{(t+1)} = \beta_{a_t}^{(t)} + (1 - r_t) \quad (6)$$

Pour les autres traitements, les paramètres restent inchangés :

$$\alpha_k^{(t+1)} = \alpha_k^{(t)}, \quad \beta_k^{(t+1)} = \beta_k^{(t)} \quad \forall k \neq a_t \quad (7)$$

4.2 Initialisation

4.2.1 Distribution A Priori

L'initialisation utilise un a priori uniforme (ou non-informatif) :

$$\alpha_k^{(0)} = 1, \quad \beta_k^{(0)} = 1 \quad \forall k \in \{1, \dots, K\} \quad (8)$$

Ceci correspond à la distribution Beta(1, 1), qui est équivalente à la distribution uniforme sur $[0, 1]$.

4.3 Propriétés Mathématiques

4.3.1 Espérance et Variance

Pour une distribution Beta avec paramètres (α, β) , les statistiques suivantes s'appliquent :

4.3.2 Moyenne

$$\mathbb{E}[\theta|\alpha, \beta] = \frac{\alpha}{\alpha + \beta} \quad (9)$$

Cette valeur représente l'estimation ponctuelle de la probabilité de succès.

4.3.3 Variance

$$\text{Var}[\theta|\alpha, \beta] = \frac{\alpha\beta}{(\alpha + \beta)^2(\alpha + \beta + 1)} \quad (10)$$

4.3.4 Mode et Convergence

Le mode de la distribution Beta est donné par :

$$\text{Mode}[\theta|\alpha, \beta] = \frac{\alpha - 1}{\alpha + \beta - 2} \quad \text{pour } \alpha, \beta > 1 \quad (11)$$

4.3.5 Concentration de la Probabilité

Au cours du temps, à mesure que les observations s'accumulent, la variance diminue :

$$\lim_{n \rightarrow \infty} \text{Var}[\theta|n\alpha_\infty, n\beta_\infty] = 0 \quad (12)$$

où n est le nombre total d'observations. Cette propriété garantit la convergence vers la véritable probabilité de succès.

4.4 Analyse de Performance

4.4.1 Regret Cumulatif

Le regret cumulatif après T itérations est défini comme :

$$R(T) = \sum_{t=1}^T (r_{\max}(t) - r_{a_t}(t)) \quad (13)$$

où $r_{\max}(t)$ est la récompense du traitement optimal et $r_{a_t}(t)$ est la récompense obtenue.

4.4.2 Borne du Regret

Thompson Sampling atteint un regret logarithmique :

$$R(T) = O(\log T) \quad (14)$$

Cette borne est asymptotiquement optimale pour les bandits à deux bras et proche de l'optimal pour les bandits généraux.

4.4.3 Taux de Convergence

La probabilité que le traitement k soit sélectionné à l'étape t converge vers :

$$\lim_{t \rightarrow \infty} P(a_t = k) = \begin{cases} 1 & \text{si } k = k^* \text{ (optimal)} \\ 0 & \text{sinon} \end{cases} \quad (15)$$

4.5 Avantages Théoriques

4.5.1 Optimalité Bayésienne

Thompson Sampling minimise le regret bayésien attendu :

$$\arg \min_{\pi} \mathbb{E}_{P(\theta)}[R_T(\pi)] \quad (16)$$

où π est une politique et $P(\theta)$ est la distribution a priori sur les paramètres.

4.5.2 Absence de Paramètres de Réglage

Contrairement à certaines stratégies (comme ϵ -greedy), Thompson Sampling n'a pas de paramètres à ajuster :

Thompson Sampling : aucun paramètre à tuner

4.5.3 Adaptation Automatique

L'algorithme s'adapte automatiquement à l'incertitude :

$$\text{Exploration} \propto \sqrt{\frac{\alpha\beta}{(\alpha + \beta)^2(\alpha + \beta + 1)}} \quad (17)$$

4.6 Comparaison avec Autres Stratégies

4.6.1 Stratégie Aléatoire

La stratégie aléatoire sélectionne uniformément :

$$P(a_t = k) = \frac{1}{K} \quad \forall k, \forall t \quad (18)$$

Regret : $R(T) = O(T)$

4.6.2 Stratégie Cyclique

La stratégie cyclique sélectionne séquentiellement :

$$a_t = (t \bmod K) \quad (19)$$

Regret : $R(T) = O(T)$

4.6.3 Thompson Sampling

$$\text{Thompson Sampling : } R(T) = O(\log T) \quad (20)$$

Thompson Sampling surpasse les deux autres stratégies pour de grandes valeurs de T .

4.7 Formulation Matricielle

Soit $\boldsymbol{\alpha} = (\alpha_1, \dots, \alpha_K)^T$ et $\boldsymbol{\beta} = (\beta_1, \dots, \beta_K)^T$ les vecteurs de paramètres.

L'algorithme peut être formalisé comme :

$$\boldsymbol{\theta}^{(t)} \sim \text{Beta}(\boldsymbol{\alpha}^{(t)}, \boldsymbol{\beta}^{(t)}) \quad (21)$$

$$a_t = \arg \max_k \theta_k^{(t)} \quad (22)$$

$$\boldsymbol{\alpha}^{(t+1)} = \boldsymbol{\alpha}^{(t)} + r_t \mathbf{e}_{a_t} \quad (23)$$

$$\boldsymbol{\beta}^{(t+1)} = \boldsymbol{\beta}^{(t)} + (1 - r_t) \mathbf{e}_{a_t} \quad (24)$$

où $\mathbf{e}_k$ est le vecteur unitaire.

4.8 Propriétés de Conjugaison

La famille Beta-Bernoulli satisfait la propriété de conjugaison :

$$\text{Beta}(\alpha, \beta) + \text{Bernoulli}(p) \rightarrow \text{Beta}(\alpha + p, \beta + (1 - p)) \quad (25)$$

Cette propriété garantit que la mise à jour reste analytiquement traitable sans approximation.

4.9 Limites Informatiques

En pratique, il faut considérer les limites numériques :

$$\text{Débordement potentiel pour } \alpha_k + \beta_k \gg 10^{308} \quad (26)$$

Une normalisation logarithmique peut être appliquée pour éviter ce problème.

4.10 Cas Multidimensionnel

Pour des espaces de paramètres multidimensionnels, on peut généraliser avec la distribution Dirichlet :

$$\boldsymbol{\theta} \sim \text{Dirichlet}(\boldsymbol{\alpha}) \quad (27)$$

où $\boldsymbol{\alpha} = (\alpha_1, \dots, \alpha_K)$ avec $\sum_k \alpha_k = n$.

4.11 Interprétation

L'algorithme Thompson Sampling fournit une approche élégante et théoriquement fondée pour résoudre le problème des bandits manchots. En utilisant les distributions Beta et la mise à jour bayésienne, il atteint un équilibre optimal entre exploration et exploitation.

Les propriétés mathématiques garantissent :

- Une convergence asymptotique vers le traitement optimal
- Un regret logarithmique asymptotiquement optimal
- Une adaptation automatique à l'incertitude
- L'absence de paramètres de réglage

Conclusion

Nous avons étudié plusieurs stratégies de sélection de traitements médicaux.

Les stratégies aléatoire et cyclique sont simples à mettre en œuvre, mais elles ne permettent pas d'exploiter les meilleurs traitements.

La stratégie du meilleur traitement observé introduit une phase d'apprentissage qui améliore significativement les performances.

Enfin, la stratégie bayésienne apparaît comme la plus performante, car elle adapte continuellement les probabilités à partir des données observées.

Ces approches illustrent le compromis fondamental entre exploration et exploitation, au cœur des algorithmes d'apprentissage par renforcement.